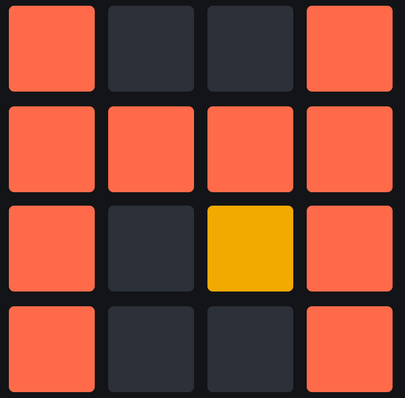
SAFENET KZ · ШЫМКЕНТ 2026 · ВСЕ ТРИ ТРЕКА



ПРУФ

Мошенники меняют слова, но таскают одни и те же пруфы. По ним мы и находим схемы.

Розыгрыши · скрытое казино · пирамиды · ru, kk, транслит · дашборд аналитика + бот @pruf_check_bot

Три схемы, один почерк

ТРЕК 1 · РОЗЫГРЫШИ

«Вы выиграли iPhone! Оплатите доставку 2 500 тг на Kaspi»

ТРЕК 2 · СКРЫТОЕ КАЗИНО

«С 5к поднял 230к за вечер, где играю — ссылка в шапке»

ТРЕК 3 · ПИРАМИДЫ

«Вход 10 000, через 7 дней забираешь 30 000. Вот скрины выплат»

Слова пишут на русском, казахском и транслите, с **«к а з и н о»** и латиницей вместо кириллицы. Модерация по стоп-словам не успевает, а ручная не масштабируется.

Примеры составлены по мотивам постов из открытых каналов, реквизиты вымышлены

ГЛАВНАЯ ИДЕЯ

Один скрин выплаты. 37 постов. 12 каналов.

Слова меняются за минуту, а скрины, номера Kaspi, голосовые и домены переиспользуются неделями. ПРУФ связывает посты через эти пруфы в кейсы, и сеть видна раньше первой жалобы.

О ПРОЕКТЕ

Одна система: находит схему, связывает сеть, предупреждает человека

Реестр пруфов

Тот же скрин выплаты, даже перерисованный, узнаётся в чужом канале

Граф кейсов

Один номер Kaspi связывает розыгрыш, казино и пирамиду в одну сеть

ru, kk, транслит

Ломаем маскировку: гомоглифы, «к а з и н о», текст на скринах и в голосовых

Агент-разведчик

Сам идёт от одной жалобы по ссылкам и общим реквизитам к соседним каналам

Расширение Sentinel

Предупреждает человека прямо в Telegram Web и Instagram, до перевода денег

Бот и отчёты

@pruf_check_bot для граждан, отчёт и архив улик для банка и АРРФР

Как ПРУФ разбирает пост

01

Нормализация

Текст, OCR скринов, голосовые. Транслит, гомоглифы, «к а з и н о», казахский на русской раскладке

02

Признаки

Словарь признаков с цитатами, стоп-признаки легальности и ML на n-граммах

03

Реестр пруфов

Почти-дубликаты скринов (PDQ), текстов (MinHash), реквизиты и домены

04

Граф кейсов

Посты, каналы, номера и пруфы складываются в кейсы и семейства кампаний

05

Аналитик

Балл 0–100, уровень риска, улики с цитатами. Решение за человеком

Формулировка всегда «найдены признаки», а не «это мошенник». Claude Sonnet подключается только в спорной зоне 20–74 балла, с дневным лимитом вызовов.

Те же слова, разный смысл

РЕКЛАМА СХЕМЫ

Высокий риск · 94

«Касса взаимопомощи! Вход 10 000 тг на Kaspi, через 7 дней забираешь 30 000. За каждого приглашённого бонус»

- Вступительный взнос: «Вход 10 000 тг на Kaspi»
- Высокая доходность: «через 7 дней забираешь 30 000»
- Доход за новых: «за каждого приглашённого»

ПРЕДУПРЕЖДЕНИЕ

Низкий риск · 10

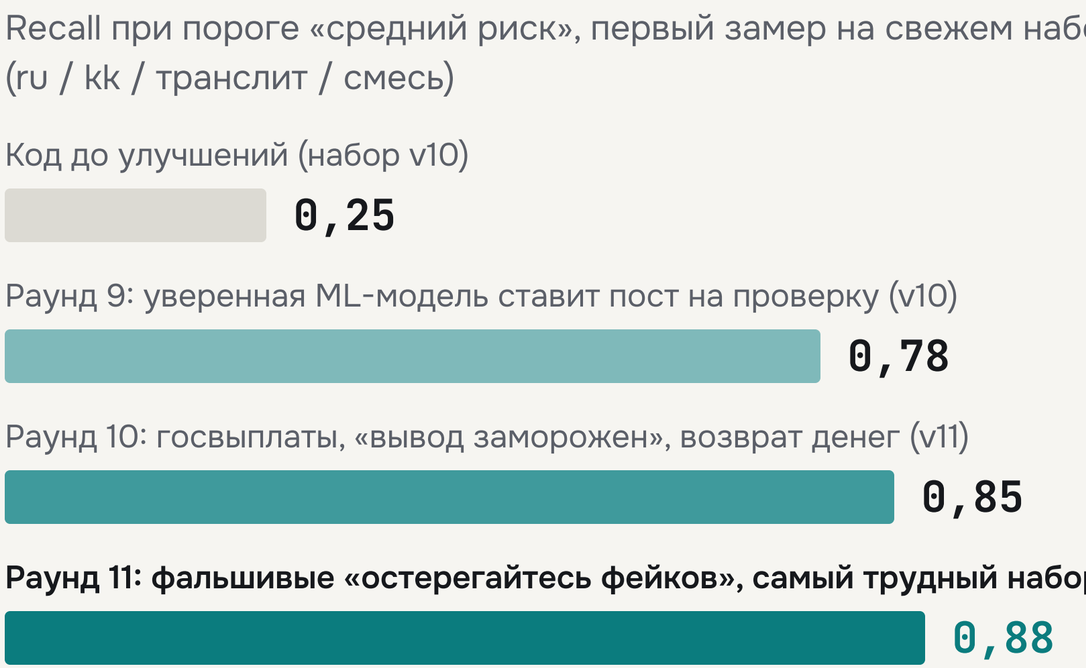
«Осторожно: „касса взаимопомощи“, где за вход 10 000 обещают 30 000 через 7 дней, — это пирамида. Не переводите деньги»

- Признак легальности: предупреждение о схеме
- Фразы в кавычках внутри предупреждения не считаются
- «Не переводите» — совет, а не просьба о деньгах

Высокий риск только при сочетании признаков. Каждая улика с цитатой из поста, методика открыта: docs/methodology.md

Честные метрики на слепых наборах

Recall при пороге «средний риск», первый замер на свежем наборе из 200 постов (ru / kk / транслит / смесь)



0,88–0,94

precision на двух последних свежих наборах (v12, v11)

+9 п.п.

recall от Claude в спорной зоне: живой замер на v10, 0,78 → 0,87, ложных тревог 5% → 4%

Каждый набор пишет отдельный агент без доступа к коду, меряем один раз. Половина набора — трудные легальные посты: предупреждения, новости, сборы, госвыплаты. Ложных тревог на них 5–12%.

docs/metrics.md: все замеры v1–v12 с интервалами Уилсона · scripts/llm_sim.py --live воспроизводит замер арбитра

Реестр пруфов видит сеть

×37

копий одного скрина выплаты в разных каналах

5

копий с подрисованной суммой: дифф сумм и дат, ELA в зоне цифр

3

трека у одного номера Kaspi: розыгрыш, казино и пирамида

⚠ Ранний сигнал: реквизит появился в 3+ каналах за 72 часа. Кейс попадает в очередь раньше первой жалобы.

Демо-сценарий кейса C-211 на синтетических данных

Три интерфейса для трёх ролей

Аналитик

Дашборд: обзор и ранние сигналы, очередь кейсов с приоритетом, граф связей, таймлайн копий пруфа, отчёт для печати и ZIP с SHA-256

Гражданин

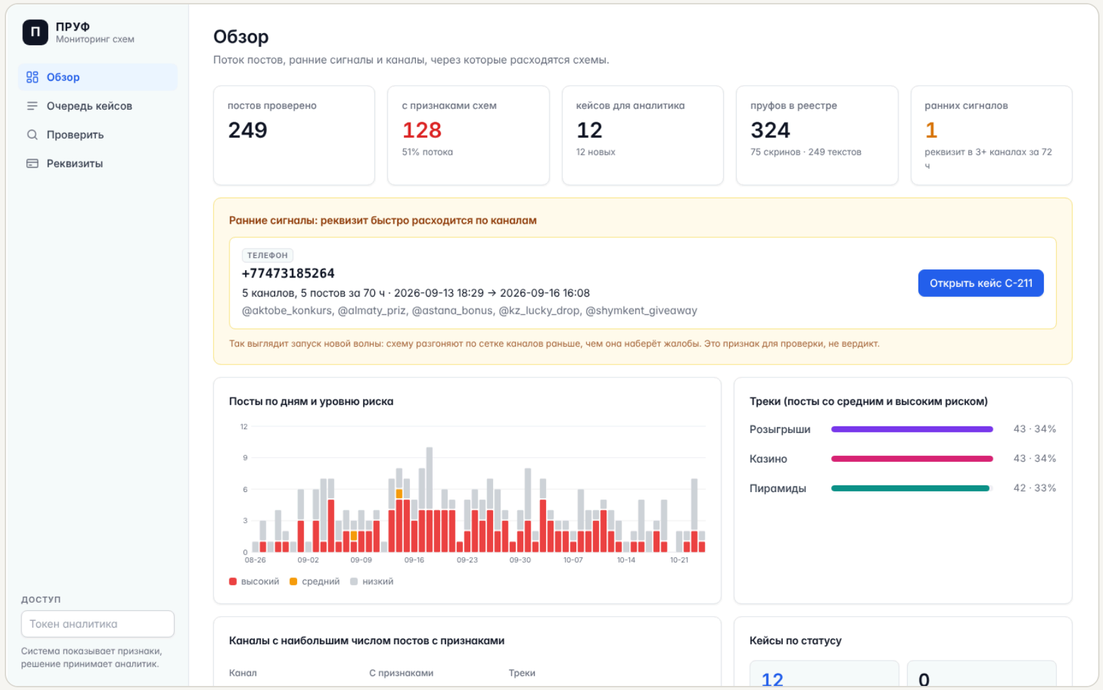
Telegram-бот @pruf_check_bot: перешли пост или скрин и узнай, встречался ли он в схемах. Базу и каналы бот не раскрывает

Банк

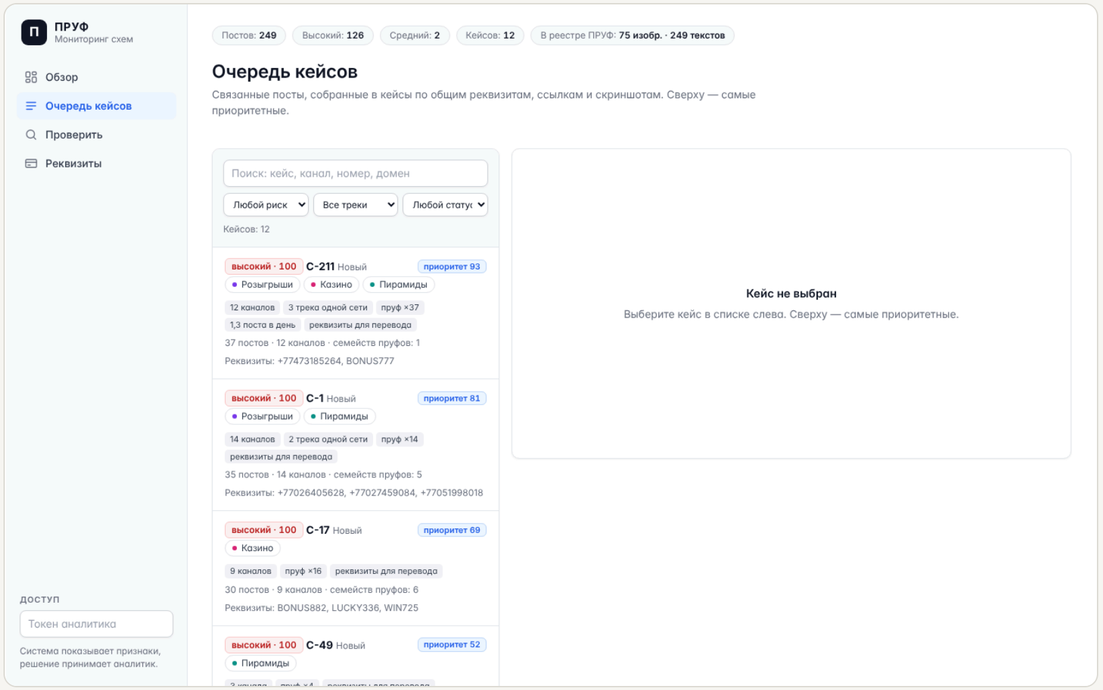
API: лента засвеченных реквизитов и проверка номера. Карты маскируются, для сопоставления хранится только HMAC

Живое демо: «Обзор» → ранний сигнал → кейс С-211 → граф → «×37 копий» → бот

Так это видит аналитик



Обзор. Динамика по трекам и ранние сигналы: реквизит в 3+ каналах за 72 часа



Кейс. Очередь по приоритету, граф связей, улики с цитатами и отчёт для печати

Живой дашборд на демо-данных: обзор, очередь кейсов, проверка поста, реквизиты для банков

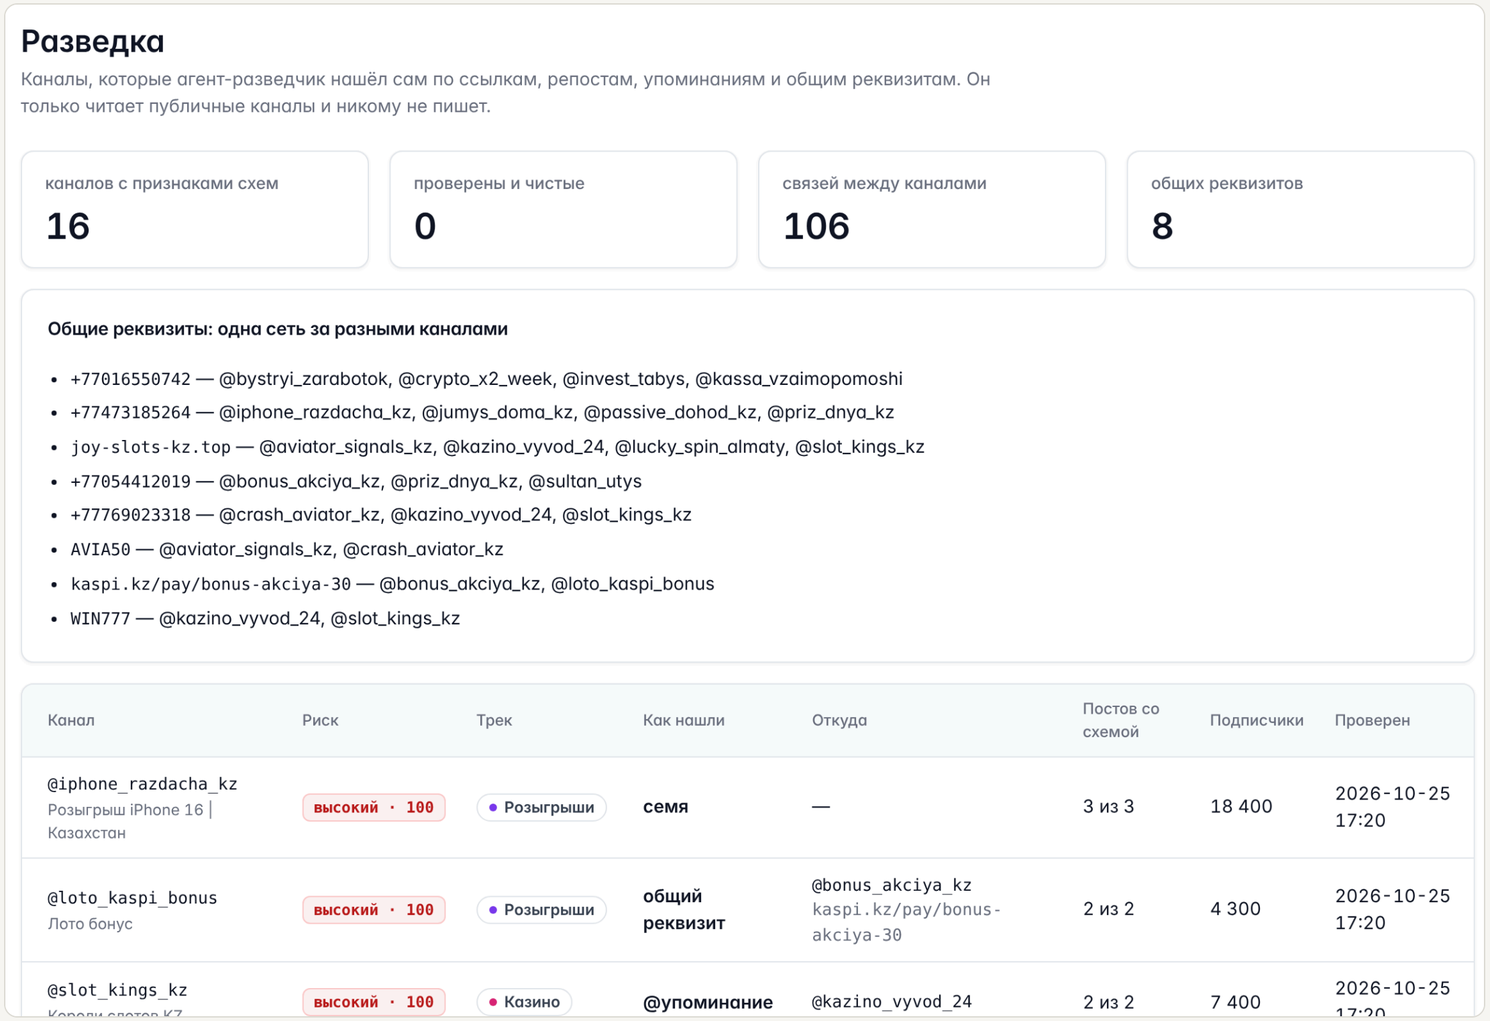
АГЕНТ-РАЗВЕДЧИК

Из одной жалобы целая сеть

15 каналов

связаны с одним каналом-жалобой. На скрине 16: жалоба и 15 найденных. Среди 8 общих реквизитов 4 номера Kaspi

Идёт по ссылкам, репостам, упоминаниям и общим реквизитам. Сначала самые подозрительные. Только читает публичные каналы и никому не пишет.



Вкладка «Разведка» в дашборде · каждый канал помнит, откуда его нашли

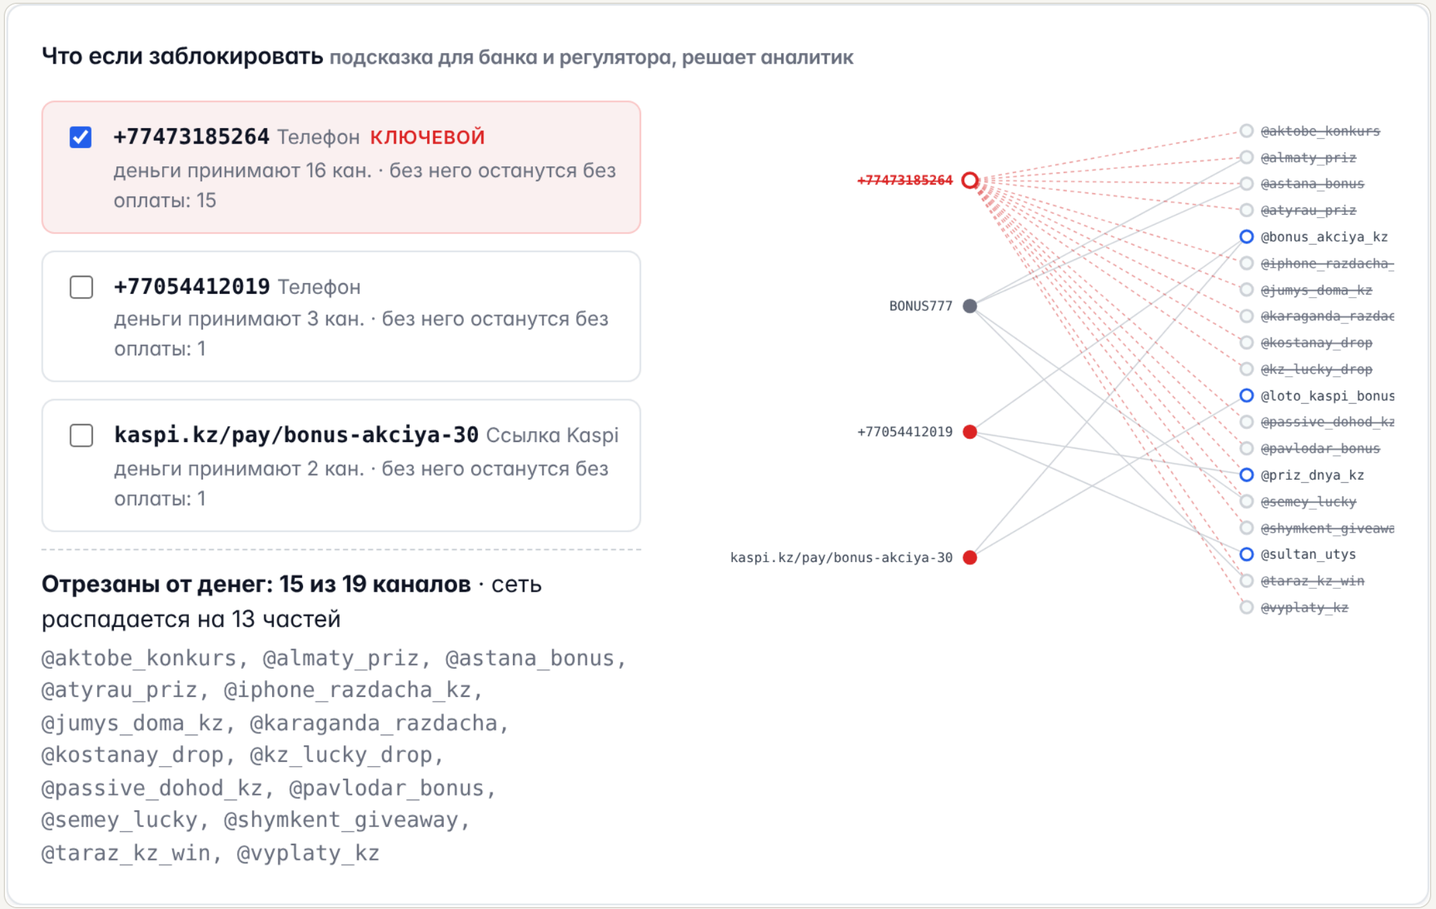
ОТ ОБНАРУЖЕНИЯ К ДЕЙСТВИЮ

Какой номер заблокировать первым

15 из 19

каналов сети остаются без способа принять деньги после блокировки одного номера Kaspi

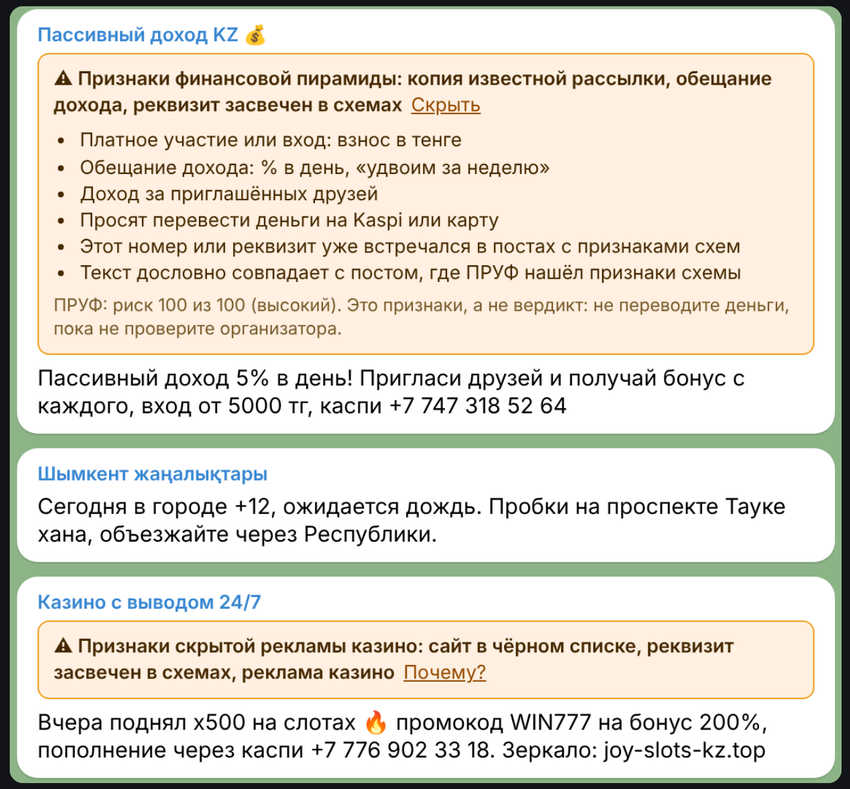
ПРУФ сам делит каналы на сети и находит ключевой реквизит каждой. Кнопка «что если заблокировать» сразу показывает, какие каналы отрезаны. Это подсказка банку и регулятору, решает аналитик.

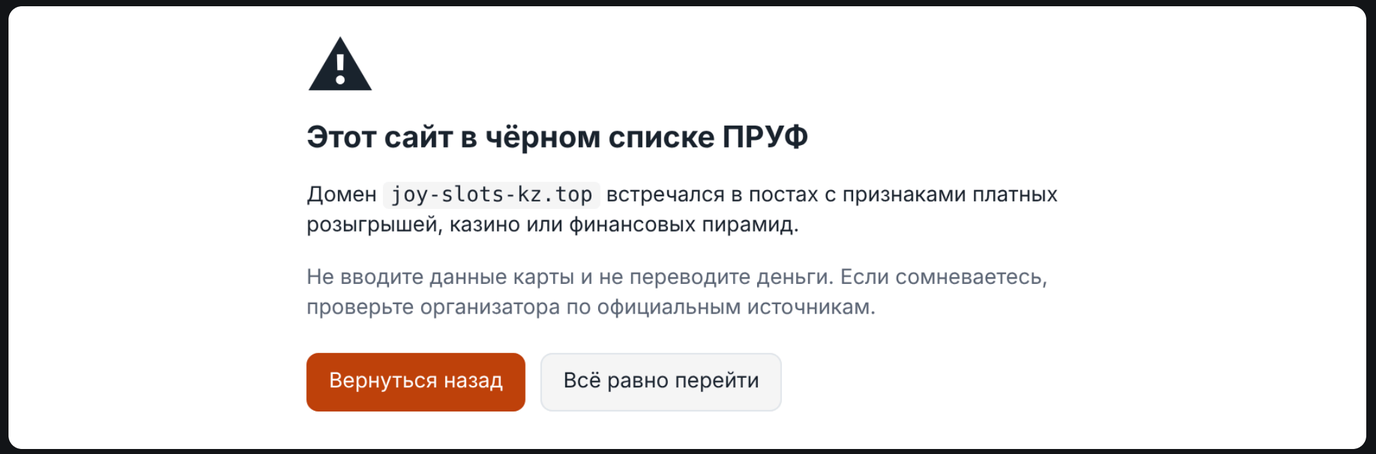


Вкладка «Разведка» и карточка кейса · граф NetworkX: сообщества Louvain и центральность узлов

РАСШИРЕНИЕ ПРУФ SENTINEL

Предупреждение до перевода денег





- Баннер над постом с риском от 65 и причины простыми словами
- Сайт из чёрного списка открывается через страницу предупреждения
- Правый клик «Проверить в ПРУФ» на любом тексте
- Наружу уходят только реквизиты, ссылки и хеш, не весь текст. Буфер обмена не читаем

Технологии

Слой	Что используем
Сервер и данные	Python, FastAPI, SQLite (Postgres на масштабе), Docker, Render
Пруфы	PDQ для почти-дубликатов скринов, MinHash LSH для текстов, RapidOCR, Whisper для голосовых
Детектор	Словарь признаков ru/kk/транслит, scikit-learn на n-граммах, граф кейсов и сетей на NetworkX (Louvain, betweenness)
ИИ-арбитр	Claude Sonnet через Claude API, только спорная зона 20–74 балла, дневной лимит вызовов
Агенты	Разведчик на Telethon (только чтение), расширение Chrome MV3 с declarativeNetRequest
Качество	700+ автотестов, E2E расширения в Playwright, ревью кода агентами Claude Code

Где увидеть агентов

Разведчик

Дашборд, вкладка «Разведка»

`GET /api/v1/scout`
`python -m pruf.scout --demo`

Sentinel

Значок ПРУФ в Chrome: попап со счётчиком проверок и блокировок, баннеры в ленте

`extension/ · POST /api/v1/inspect`

ИИ-арбитр

В разборе поста: оценка Claude, только в спорной зоне 20–74 балла

`pruf/detect/llm.py · лимит в сутки`

Агенты-ревьюеры

Security, code, python reviewer и TDD-guide проверяли каждый PR

`.claude/agents/ · PR на GitHub`

Все агенты под контролем человека: разведчик только читает, расширение только предупреждает, решение принимает аналитик.

Готово к пилоту

32 мс

поиск похожего скрина среди 1 млн (PDQ, медиана)

0,1 мс

поиск похожего текста среди 1 млн (MinHash, медиана)

1 сервер

8 vCPU / 32 ГБ на пилот, LLM только для спорной зоны

Этап	Срок	Что делаем
Подготовка	2 недели	Соглашение с партнёром, список открытых каналов, развёртывание
Пилот	8 недель	Шымкент и Туркестанская область, 2 аналитика, бот, 1–2 банка
Республика	3 месяца	Postgres, очередь для OCR и Whisper, Neo4j, кейс за 15 минут при 1 млн постов в сутки

Нагрузочный тест в репозитории; план внедрения: docs/rollout.md

ЧТО ДАЛЬШЕ

Пилот на 8 недель с APPФР и одним банком

≥ 0,9
precision на разметке аналитиков

≤ 5%
ложных срабатываний

< 1 ч
от первого поста схемы до кейса

ПРУФ: находим признаки, решает человек. Спасибо!